# Laboratorio di IU Manipolazione di Dati

https://tinyurl.com/y2jpjupw

9 marzo 2021 Rachele Sprugnoli — <u>rachele.sprugnoli@unicatt.it</u>



#### PRIMI PASSI

Come aprire la linea di comando?

- Mac & Linux: terminale (shell, bash)
  - Mac: Applications → Utilities → Terminal
- Windows: Cygwin terminal



Dove mi trovo?

Digitate pwd

Cosa c'è qui?

Digitate 1s

#### PRIMI PASSI

#### Manuale completo:

man comando (si esce con q)

man pwd

#### Aiuto sintetico:

comando --help

```
pwd --help
```

```
C:\Users\Rachele>pwd --help
Usage: pwd [OPTION]...
Print the full filename of the current working directory.

-L, --logical use PWD from environment, even if it contains symlinks
-P, --physical avoid all symlinks
--help display this help and exit
--version output version information and exit

If no option is specified, -P is assumed.

NOTE: your shell may have its own version of pwd, which usually supersedes the version described here. Please refer to your shell's documentation for details about the options it supports.
```

GNU coreutils online help: <http://www.gnu.org/software/coreutils/>
Report pwd translation bugs to <http://translationproject.org/team/>
Full documentation at: <http://www.gnu.org/software/coreutils/pwd>

or available locally via: info '(coreutils) pwd invocation'

#### PRIMI PASSI

#### Spostarsi

- cd (Change Directory) nome\_cartella
- cd spazio e poi trascinare l'icona della cartella scaricata
- cd .. per tornare indietro di una cartella

Usare il tasto **tab** (≒) per il completamento automatico e ridurre gli errori: clicco 2 volte per vedere tutti i comandi

```
Rachele@Falcon ~

$ mk

mkdir.exe mkgroup.exe mkpasswd.exe mktemp.exe

mkfifo.exe mknod.exe mkshortcut.exe
```

#### **TESTI**

#### Concatenare file di testo

• cat (conCATenare) verso1.txt verso2.txt

Come salvare il risultato in un nuovo file: >

- cat verso1.txt verso2.txt > nomefile.txt
- non vale solo per cat!

Come aggiungere un testo a un altro: >>

- cat verso2.txt >> verso1.txt
- aprite i file: cosa è successo?
- attenti alle sovrascritture!

#### STATISTICHE DI BASE

#### Usiamo il file canto1.txt:

wc (Word Count)

```
wc -l canto1.txt (conta le righe)
wc -w canto1.txt (conta le sequenze separate da spazio)
wc -m canto1.txt (conta i caratteri)
wc -c canto1.txt (conta i byte)
```

```
Rachele@Falcon /cygdrive/c/Users/Rachele/Desktop/Presentazioni_2019/Pavia $ wc -l canto1.txt

Rachele@Falcon /cygdrive/c/Users/Rachele/Desktop/Presentazioni_2019/Pavia $ wc -w canto1.txt

952 canto1.txt

Rachele@Falcon /cygdrive/c/Users/Rachele/Desktop/Presentazioni_2019/Pavia $ wc -m canto1.txt

7209 canto1.txt

Rachele@Falcon /cygdrive/c/Users/Rachele/Desktop/Presentazioni_2019/Pavia $ wc -c canto1.txt

Rachele@Falcon /cygdrive/c/Users/Rachele/Desktop/Presentazioni_2019/Pavia $ wc -c canto1.txt
```

#### STATISTICHE DI BASE

#### Usiamo il file canto1.txt:

wc (Word Count)

```
wc -l canto1.txt (conta le righe)
wc -w canto1.txt (conta le parole - sequenze separate da
spazio)
wc -m canto1.txt (conta i caratteri)
wc -c canto1.txt (conta i byte)
```

Cosa succede con questo comando?

• wc -1 \*.txt

#### RICERCHE

#### Il comando fondamentale

grep (General Regular Expression Print)
 SINTASSI: grep (-opzione) "ricerca" file

```
grep 'Dio' canto1.txt canto2.txt
```

- restituisce le righe, può esserci più di una corrispondenza per riga → attenzione alle maiuscole!
- altre opzioni utili: -i (case insensitive) --color (colorazione)


```
grep -o 'Dio' canto1.txt canto2.txt
```

- per avere solo le corrispondenze: -o

```
grep 'Dio' canto1.txt canto2.txt | wc -l
```

la pipe | concatena comandi

Linguaggio formale per definire stringhe di testo



- Link utili:
  - Tutorial interattivo: <a href="https://regexone.com/">https://regexone.com/</a>
  - Piattaforma di test online: <a href="https://regexr.com/">https://regexr.com/</a>
  - Per Sublime Text: <a href="https://tinyurl.com/r5dfj7uh">https://tinyurl.com/r5dfj7uh</a>

Pattern	Significato	Matching
[A-Z]	una lettera maiuscola	<u>C</u> hatbot
[a-z]	una lettera minuscola	<b>c</b> hatbot
[0-9]	una cifra numerica	Capitolo <u>1</u>

Pattern	Significato	Matching
gatto cane	o "gatto" o cane"	il <u>cane</u> è nella cuccia
[cC]ane [gG]atto	iniziale maiuscola o minuscola	<u>Cane, cane, gatto,</u> <u>Gatto</u>

Pattern	Significato	Matching
p.zza	qualsiasi carattere	pazza pozza pizza
pi <b>?</b> azza	0 o 1 occorrenza	piazza pazza
no*	0 o più occorrenze	<u>n no nooooo</u>
no+	1 o più occorrenze	no nooooo
[0-9]{0,3}	numero di occorrenze	<u>0</u> <u>39</u> <u>111</u>
piazza\$	fine della stringa	Tutti in <u>piazza</u>
^Piazza	inizio della stringa	Piazza pulita
piazza\.	carattere di escape	Tutti in <b>piazza.</b>

grep con opzione -E

- Tutte le occorrenze di "Ahi" ad inizio riga

- le prime parole di una riga che iniziano per maiuscola

grep -E -o '
$$^[A-Z][a-z]+'$$
 canto1.txt

- le prime parole di una riga che iniziano per maiuscola e che sono formate da almeno 2 lettere

le occorrenze di "per" o "pel"

- tutta la punteggiatura

## **FILE TSV/CSV**

Selezionare/filtrare una o più colonne di dati Apriamo il file BellumGallicum.txt (con Sublime Text) e BellumGallicum.csv (con LibreOffice Calc)

Comando cut

```
cut -f 3 BellumGallicum.txt
```

- opzione -f per specificare il numero della colonna da selezionare, la numerazione parte da 1

```
cut -f 3,1 BellumGallicum.txt
```

- seleziono sia la terza che la prima colonna

```
cut -f 2 -d ',' BellumGallicum.csv
```

 se le colonne non sono divise da \tab, specifico il delimitatore di campo con l'opzione -d

## **USIAMO PIÙ COMANDI**

Provate ad eseguire i seguenti comandi: qual è il risultato? Cosa fanno sort, uniq, uniq -c?

```
cut -f 3 BellumGallicum.txt | sort

cut -f 3 BellumGallicum.txt | sort | uniq

cut -f 3 BellumGallicum.txt | sort | uniq -c

cut -f 3 BellumGallicum.txt | grep "NOUN" | wc -l

cut -f 1,3,5 BellumGallicum.txt | grep "NOUN" | grep
"Plur"
```

#### **ESPRESSIONI REGOLARI SU SUBLIME TEXT**

- Apriamo Letters.txt con Sublime Text: si tratta dell'indice del libro "The Letters of Anne Gilchrist and Walt Whitman"
  - → trasformiamo l'indice in un foglio di calcolo con 4 colonne: mittente, destinatario, luogo del mittente, data
  - → da dato non strutturato (testo) a dato strutturato (tabella)
  - → possibile input di strumenti di network analysis
- Ctrl+h (Windows) o alt+cmd+F (Mac) per aprire la finestra di Replace
- Selezionare le opzioni 1,2 e 4 sulla sinistra



#### **ESPRESSIONI REGOLARI SU SUBLIME TEXT**

#### Eseguire i seguenti passi uno alla volta

- 1. eliminare gli spazi all'inizio di ogni riga: ^( )\* --> nulla
- 2. togliere il numero di pagina: ()\*[0-9]+\n --> nulla
- 3. mettere informazioni sulla stessa riga: \n\_ --> \_
- 4. togliere i numeri romani iniziali: ^[A-Z]+\. --> nulla
- 5. aggiungere tabulazioni come separatori di colonne: \_ --> \t
- 6. togliere virgola prima degli anni: , ([0-9]{4}) --> \1
- 7. togliere doppi tab: \t\t --> \t
- 8. dividere mittente e destinatario: TO --> \t

Alla fine copiare e incollare su un foglio di calcolo e aggiungere nomi alle colonne

#### **MODIFICARE TESTI**

- Comando tr (TRanslation)
- tr carattere1 carattere2 < testo1.txt > testo2.txt
  - si possono usare le classi [:punct:], [:lower:], ...
  - opzione -d (delete): cancella i caratteri scelti
  - attenzione: < input; > output

```
tr -d "[[:punct:]]" < canto1.txt > canto1_nopunct.txt

tr "[[:upper:]]" "[[:lower:]]" < canto1_nopunct.txt >
canto1_minuscole.txt

tr " " "\n" < canto1_minuscole.txt > canto1_parole.txt

sort canto1-parole.txt | uniq -c | sort
```



## **GRAZIE!**

Email: rachele.sprugnoli@unicatt.it

Twitter: @RSprugnoli



